Hermes-DQN：相關研究與支持數據（2025–2026）

執行摘要

本報告針對 Hermes-DQN 研究框架中提出的三大核心問題——稀疏獎勵、缺乏跨輪記憶、LLM 自動獎勵設計與 DQN 不相容——彙整 2025–2026 年間最新的學術文獻與實驗數據，並提供 Hermes Agent、Gemma 4 31B 及 Gymnasium 基準測試等相關技術背景。

一、研究背景：稀疏獎勵問題的嚴峻性

稀疏獎勵（Sparse Reward）是深度強化學習領域最根本的挑戰之一。在稀疏設定下，智能體可能在數百個時間步內完全無法獲得有效回饋，導致學習效率極低甚至無法收斂。[1][2]

斯坦福 CS224R 深度強化學習課程（2025 年春季）明確指出：「在稀疏獎勵場景中，探索問題真的非常困難。智能體必須找到一系列行動，每個單獨的動作可能沒有獎勵，但組合起來才能獲得回報。」這正是 Hermes-DQN 選擇以自動獎勵設計來提供密集引導訊號的核心動機。[3][2]

近期研究支持數據

- DISCOVER（NeurIPS 2025 / ICML 2025）：ETH Zürich 的研究提出了針對稀疏獎勵的自動課程學習方法（DISCOVER），指出稀疏獎勵的 RL 是「需要高效探索配合長程信用分配的核心難題」，是建立超人能力自改進智能體的關鍵。[4][5]
- Taiwan JIT 2025 研究（國立宜蘭大學）：在稀疏獎勵任務中，大量無用樣本導致樣本效率下降並陷入局部最優解，提出自平衡探索與利用策略以解決此問題。[^1]
- ICLR 2025 優先生成性回放（Prioritized Generative Replay）：研究表明標準回放緩衝區在稀疏獎勵環境下多樣性不足，提出生成式世界模型來合成更具探索性的過渡樣本。[^6]

二、現有問題一：依賴商業 API 的代價

問題說明

主流 LLM 獎勵設計框架（以 EUREKA 為代表）仰賴 GPT-4 等閉源商業模型，不僅有 API 費用，也存在數據隱私疑慮。[^3]

研究現況

EUREKA（ICLR 2024）是目前最重要的 LLM 自動獎勵設計基準，利用 GPT-4 的零樣本代碼生成和上下文演化能力，在 29 個 RL 環境中，以平均 52% 的提升幅度超越了人類專家設計的獎勵函數，並在 83% 的任務上勝過人類。[7][8]

然而，這種對頂級閉源模型的依賴帶來了系統性風險：

- LEARN-Opt（arXiv, Nov 2025）：Franklin Cardenoso 等人指出「自動獎勵設計是一個高變異問題，平均水準的候選方案往往失敗，需要多次運行才能找到最佳候選」，研究同時證明低成本 LLM 可以找到與更大模型相當甚至更優的高性能候選方案。[^9]
- CARD（Knowledge-Based Systems, 2025）：提出在不依賴人工標注或大量 RL 訓練的情況下，利用 LLM 迭代生成並優化獎勵代碼的框架，在 Meta-World 和 ManiSkill2 上達到或超越專家設計獎勵，其中 12 個任務中的 10 個達到等效或更優性能。[10][11]

Gemma 4 31B：可行的開源替代方案

Hermes-DQN 採用 Google 的 **Gemma 4 31B** 搭配 Google AI Studio API 作為開源替代方案，以下數據支持其可行性：

基準測試	Gemma 3 27B（前代）	Gemma 4 31B（2026）	意義
LiveCodeBench v6	29.1%	80.0%	真實世界編程能力[^12]
MMLU Pro	67.6%	85.2%	跨領域邏輯推理[^13]
AIME 2026（無工具）	20.8%	89.2%	複雜算法開發[^13]
Codeforces ELO	110	2150	競技級程式設計[^13]
Big Bench Hard	19.3%	74.4%	多步邏輯推理[^12]

Gemma 4 31B 在 LM Arena 開源模型排行榜中位居第三名，支援 256K token 上下文視窗、原生函數呼叫及代碼生成，在 Google AI Studio 上提供每日免費額度，完全消除閉源依賴。[14][15] [^16]

三、現有問題二：缺乏跨輪記憶的效率損失

問題說明

現有框架（如 EUREKA）的語言模型缺乏跨輪記憶，每次生成獎勵函數時不記得上次哪裡出錯，容易反覆犯同樣的錯誤，搜索效率極低。[^3]

持久記憶研究的重要性（2025–2026）

Emergent Mind（2025 年 8 月更新）綜述指出：「持久記憶為 LLM 智能體提供長期保留、動態組織和選擇性提取的結構化框架，對穩健的序列決策至關重要。進階演算法整合強化學習和層次記憶模組來高效管理儲存的互動，無需重新訓練核心模型參數。」[^17]

關鍵研究佐證：

- MemRL（arXiv, Feb 2026）：提出透過情節記憶上的強化學習實現自演化智能體的非參數方法，在 HLE、BigCodeBench、ALFWorld 和 Lifelong Agent Bench 等四個基準上表現優於基線，在探索密集環境中取得相對改進。[^18]
- 記憶管理影響研究（May 2025）：系統性研究顯示，選擇性添加和刪除記憶可將智能體長期性能提升 10%，並降低錯誤傳播和錯位經驗重用的風險。[^17]
- mem-agent（HuggingFace/Dria, Oct 2025）：以 4B LLM 智能體透過 RL 訓練實現持久記憶，在 md-memory-bench 上達到 75% 分數，僅次於 Qwen3-235B-A22B-Thinking。[^19]

Hermes Agent 的記憶架構

Nous Research 於 2026 年 2 月正式發布 Hermes Agent，其多層記憶系統恰好針對上述問題提供工業級解方：[20][21]

記憶層級	功能	對應能力
Small Context	短期工作記憶	當前任務快速讀取
Searchable History	使用 SQLite FTS5 + LLM 摘要的長期儲存	跨會話回憶
Optional Modeling	使用者偏好建模	主動預測需求
Procedural Memory（Skill Documents）	成功工作流程蒸餾為可複用技能	避免重蹈覆轍

^22

根據 i-SCOOP 的分析，Stanford HAI AI Index 2026 指出 AI 智能體在結構化基準測試上仍有約三分之一的任務失敗率，而 OSWorld 上的準確率已從約 12% 提升至 66.3%，接近人類水準的六個百分點之內——這表明記憶、工作流程復原和工具編排比單純的模型智能更為關鍵。[^24]

四、現有問題三：DQN 與 LLM 獎勵設計的不相容性

問題說明

現有方法幾乎都只搭配 PPO 演算法。DQN 的訓練記憶庫（Replay Buffer）中，當獎勵規則中途改變時，舊資料與新規則互相矛盾，會導致學習崩潰。[^3]

非平穩性與 Replay Buffer 的研究背景

ICLR 2025（LCPO 論文）深入分析了非平穩環境中 DRL 的挑戰：「在非平穩環境中，一個核心挑戰是災難性遺忘（CF）。基於函數近似的智能體在依次對非平穩數據進行訓練時，往往會忘記過去的知識。離線策略 RL 算法（如 DQN）允許在舊數據上重新訓練，從而規避了序列學習的陷阱，但代價是超參數敏感性增加和訓練不穩定。」[^25]

更直接的問題：在獎勵函數改變後，Replay Buffer 中儲存的舊轉移數據（s, a, r, s'）的 r 值已不再反映新獎勵規則，用這些舊數據更新 Q 網路會引入偏差。這正是 Hermes-DQN 需要 AST 感知緩衝區管理的核心原因。[^3]

研究現況佐證：

- NeurIPS 2024（Churn Chain Effect）：研究發現 DRL 中「churning」現象——批次更新後未包含在批次中的狀態預測發生不受控制的變化，這種效應在獎勵非平穩時更加嚴峻，在基於值的方法中導致貪心動作偏差。[^26]
- ShadeCoder 2025 DQN 指南：指出「2025 年業界趨勢持續關注改善 DQN 的樣本效率、在非平穩環境中的魯棒性，以及與其他現代 ML 技術的整合」。[^27]
- LLM-Explorer（NeurIPS 2025）：提出與 DQN 系列、DDPG、TD3 相容的插件式 LLM 探索模組，在 Atari 和 MuJoCo 基準上實現最高 37.27% 的平均性能提升，這是 LLM 與 DQN 整合可行性的直接證據。[^28]

- CARD 框架：透過軌跡偏好評估（TPE）繞過重複 RL 訓練，在 12 個任務中的 10 個超越或等同人類設計的獎勵，其核心思路類似於 Hermes-DQN 的 AST 差異分析——減少不必要的完整重訓。[^10]

五、Gymnasium 基準環境的正當性

Hermes-DQN 選擇 CartPole-v1 與 LunarLander-v3 作為測試環境，以下研究支持其代表性：

Gymnasium（arXiv 2025）正式論文指出：Gymnasium 是廣泛採用的 RL 環境標準介面，截至 2025 年 4 月已超過 100 萬次下載，總安裝量超過 1,800 萬次，為研究人員提供了可比較的基準。[29][30]

LunarLander DQN 基準數據（IJRPR 2025）：

- DQN 智能體在 LunarLander-v2 上通常需要約 1,200 個 episode 才能達到解決門檻（平均回報 ≥ 200）
- DQN 最終評估的平均 episode 回報為 210.5，成功率 92%，標準差 ±32
- A2C 更快收斂（900–1,000 個 episode），但穩定性略低（標準差 ±41）
- 研究確認結合適當的獎勵塑形，DQN 可達到平均回報 233.21，成功率 85%[^31]

這些數據確立了 Hermes-DQN 框架中「首次達標所需輪次數」評估指標的參照基準。

六、自動獎勵設計的整體趨勢（2025–2026）

論文 / 框架	發表時間	核心貢獻	與 Hermes-DQN 的關聯
EUREKA	ICLR 2024	首次以 GPT-4 實現人類水準獎勵設計	基準對照框架（Stateless 設定）[^7]
LEARN-Opt	Nov 2025	無需環境源碼的自主獎勵設計	支持低成本 LLM 替代方案的可行性[^9]
CARD	KBS 2025	迭代代碼生成+軌跡偏好評估	減少重複訓練的策略佐證[^10]
LLM-Explorer	NeurIPS 2025	與 DQN 相容的 LLM 探索插件	直接支持 LLM+DQN 整合的可行性[^28]
MemRL	Feb 2026	基於情節記憶的 RL 自演化智能體	支持跨輪記憶對性能的正面影響[^18]
Hermes Agent	Feb 2026	具備持久記憶與技能蒸餾的開源智能體	核心框架組件，提供記憶與技能系統[20][23]
Gemma 4 31B	Apr 2026	開源前沿推理模型（LiveCodeBench 80%）	消除商業 API 依賴的核心組件[12][13]

七、研究缺口與 Hermes-DQN 的創新定位

現有文獻中存在明顯缺口，恰好是 Hermes-DQN 所填補的：

1. LLM 記憶機制與獎勵演化的結合：目前 MemRL、mem-agent 等記憶研究主要針對任務型智能體，尚未有工作系統性地將跨輪記憶機制應用於*獎勵函數設計流程*本身的迭代優化。[19][18]

2. DQN 的 Replay Buffer 與動態獎勵的相容性：大量研究關注 PPO 的獎勵設計，但針對 DQN 的 Replay Buffer 在獎勵更迭時的緩衝區管理策略至今缺乏系統性解方。[25][3]
3. 開源本地部署的完整流水線：LEARN-Opt 等工作已證明低成本 LLM 的可行性，但尚未有框架以 Hermes Agent + 開源 API 的形式，實現從獎勵生成到記憶蒸餾、再到 DQN 訓練的完整閉環自動化流水線。[23][9]

這三個缺口的同時存在，構成了 Hermes-DQN 在 2025–2026 年研究景觀中的明確定位與貢獻空間。

References

1. [PDF] Solving Sparse Reward Tasks Using Self-Balancing Exploration and ... - A core challenge in applying deep reinforcement learning (DRL) to real-world tasks is the sparse rew...
2. Stanford CS224R Deep Reinforcement Learning | Spring 2025 - View course details: https://online.stanford.edu/courses/xcs224r-deep-reinforcement-learning May 16,...
3. Hermes-DQN_Introduction_Zheng-Shi-Ban-_Wen-Jian-Dang.pdf - page-1
4. Introduction學Hermes-DQN：基於 Hermes Agent 與 Gemma 4 31B 之自動化強化學習獎勵設計框架學完整架構版本 · 2026學A. ...
5. Automated Curricula for Sparse-Reward Reinforcement Learning - Sparse-reward reinforcement learning (RL) can model a wide range of highly complex tasks. Solving sp...
6. Automated Curricula for Sparse-Reward Reinforcement Learning - Sparse-reward reinforcement learning (RL) can model a wide range of highly complex tasks. Solving sp...
7. [PDF] PRIORITIZED GENERATIVE REPLAY - ICLR Proceedings - Sample-efficient online reinforcement learning often uses replay buffers to store experience for reu...
8. Eureka: Human-Level Reward Design via Coding Large ... - Large Language Models (LLMs) have excelled as high-level semantic planners for sequential decision-m...
9. Eureka | Human-Level Reward Design via Coding Large ...
10. Leveraging LLMs for reward function design in reinforcement ... - arXiv - This demonstrated performance affirms its potential to generate high-quality reward functions withou...
11. A large language model-driven reward design framework via ... - We propose CARD, an LLM-driven Reward Design framework that generates and improves reward function c...
12. A large language model-driven reward design framework via ... - ACM - Large Language Models (LLMs) have shown significant potential in designing reward functions for Rein...
13. Gemma 4 Coding Benchmark: Full Performance Analysis 2026 - Explore the comprehensive Gemma 4 coding benchmark results. Learn how Google's latest open-weight mo...
14. Google Gemma 4 效能實測報告：跑分大幅拋離上代，31B 與26B ... - Google 最新推出嘅 Gemma 4 開源 AI 模型系列，官方基準測試（Benchmark）成績正式曝光。數據顯示，Gemma 4 喺邏輯推理、編程及多模態處理上，效能大幅拋離上一代 Gemma...
15. Gemma 4 API Tutorial: Vertex AI and Google AI Studio Integration ... - Complete 2026 Gemma 4 API integration tutorial: Google AI Studio for free quick start vs Vertex AI f...

16. Gemma 4 Coding Performance Benchmarks 2026 - Explore the comprehensive Gemma 4 coding performance benchmarks 2026. See how Google's open-source m...
17. Gemma 4 31B for Pentesting, Local Reasoning with Guardrails - Gemma 4 31B can be a strong local reasoning core for pentesting, but only inside a guarded workflow....
18. Persistent Memory in LLM Agents - Emergent Mind - Persistent memory in LLM agents uses dynamic organization, selective retrieval, and reinforcement le...
19. MemRL: Self-Evolving Agents via Runtime Reinforcement Learning ... - Our objective is to achieve an agent that evolves with continued usage and rapidly adapts to new tas...
20. mem-agent: Equipping LLM Agents with Memory Using RL - This paper introduces mem-agent, a 4B LLM agent trained with GSPO on a scaffold that uses Python too...
21. Nous Research Releases 'Hermes Agent' to Fix AI Forgetfulness ... - Nous Research Releases 'Hermes Agent' to Fix AI Forgetfulness with Multi-Level Memory and Dedicated ...
22. Nous Research released Hermes Agent in February 2026, an open ... - LangGraph – For Stateful Agents Graph-based framework for advanced agent routing, orchestration, and...
23. Hermes Agent 是什麼？Nous Research 如何用「會記憶的AI」改變 ... - Hermes Agent 是由 Nous Research 開發的開源AI Agent，具備四層記憶系統、內建學習循環與自動技能生成。本文完整解析其核心架構、與傳統AI 助理的 ...
24. Hermes Agent Documentation - The self-improving AI agent built by Nous Research. A built-in learning loop that creates skills fro...
25. Hermes Agent from Nous Research - i-SCOOP - Hermes prioritizes learning depth, memory quality and tighter operational controls. That difference ...
26. [PDF] ONLINE REINFORCEMENT LEARNING IN NON-STATIONARY ... - We study online reinforcement learning (RL) in non-stationary environments, where a time-varying exo...
27. Improving Deep Reinforcement Learning by Reducing the Chain ... - We discover a chain effect of churn that leads to a cycle where the churns in value estimation and p...
28. Deep Q-network - Practical Guide for 2025 | ShadeCoder - Industry trends in 2025 show continued interest in improving DQN's sample efficiency, robustness to ...
29. NeurIPS Poster LLM-Explorer: A Plug-in Reinforcement Learning ... - Our design is a plug-in module compatible with various widely applied RL algorithms, including the D...
30. A Standardized Interface for Reinforcement Learning Environments - This paper introduces Gymnasium, an open-source library offering a standardized API for RL environme...
31. [PDF] Gymnasium: A Standard Interface for Reinforcement Learning ... - Gymnasium is the maintained successor to OpenAI Gym, which has become widely adopted, with over a mi...
32. [PDF] Lunar Lander: Deep Q-Learning Approach for Autonomous ... - ijrpr - This research focuses on implementing and training a reinforcement learning (RL) agent capable of su...