

Hermes-DQN: 記憶擴增之大型語言模型獎勵設計何時對 DQN 有效? 四環境分析

陳盛茂、林仙安、辛語柔、陳冠宇

國立中興大學 資訊管理學研究所

摘要

EUREKA (Ma et al., ICLR 2024) 已指出大型語言模型 (Large Language Model, LLM) 所撰寫的獎勵函數 (reward function) 可在 83% 的任務上勝過人工調校的塑形獎勵 (shaping reward)。延續此一發現, 後續研究普遍預設此一作法可順利推廣, 並提出三項擴增方向: 其一是改採開源 LLM 以降低成本與依賴, 其二是加入跨迭代記憶 (cross-iteration memory) 以促進精進, 其三是強化重播緩衝區 (replay buffer) 以維持訓練穩定。本論文提出「Hermes-DQN」並一次整合上述三項擴增: 採用 Google Gemma 4 31B 作為獎勵作者、運用 Nous Research Hermes Agent 啟發之四層級記憶架構 (Procedural / Semantic / Episodic / Working), 以及一個感知抽象語法樹 (Abstract Syntax Tree, AST) 之重播緩衝管理器。實驗於 Gymnasium 四個古典控制環境 (LunarLander-v3、CartPole-v1、MountainCar-v0、Acrobot-v1) 上, 以六種條件、每條件五個隨機種子進行系統性消融研究。結果呈現出「任務相依性反轉」(task-dependent reversal): 在三個稀疏獎勵 (sparse reward) 環境中, B3-hermes-full 較原生基準 (vanilla baseline) 提升約 32–116%, 其中 2/3 達 $p < 0.05$ 統計顯著; 而在唯一的密集獎勵 (dense reward) 環境中, Hermes 與原生基準在統計上無差異, 且記憶機制反而與績效下降相關 ($p = 0.0317$, -38%)。變異性指紋同步翻轉: 於本實驗條件下, Hermes 於物理簡單的稀疏環境上極度穩定 ($\text{std} = 3-4$), 於塑形空間豐富的密集環境上卻呈現高變異 ($\text{std} = 91$, 並出現一個近乎崩潰的種子)。本研究據此指出: LLM 撰寫之獎勵設計在所測試之配置下並非通用工具, 其價值受制於主任務之獎勵稀疏程度, 並建議將「獎勵密度」(reward density) 作為其適用性之候選預測指標。

關鍵字: 深度強化學習; LLM 作為獎勵作者; 開源大型語言模型; 消融研究; 跨任務泛化

1 Introduction

深度強化學習 (Deep Reinforcement Learning, DRL) 長期受制於獎勵函數設計問題。稀疏的環境獎勵會使智能體 (agent) 難以收斂, 過度塑形的獎勵又會引入不易察覺的偏誤, 進而破壞訓練穩定性。實務上仰賴人工反覆調整塑形項的作法, 並不具備可擴展性。

EUREKA (Ma et al., 2024) 首先示範了 GPT-4 能撰寫出在 83% 的 Isaac Gym 任務上優於人工設計的獎勵函數, 平均改善幅度達 52%。後續研究沿著兩個方向持續推進:

1. 以開源 LLM 取代商用 API: CARD (Sun et al., 2024) 與 LEARN-Opt (Cardenoso & Caarls, 2025) 均指出封閉式 API 不利於可重現性與離線部署。
2. 引入跨迭代記憶: Stanford HAI 《AI Index 2026》報告指出, OSWorld 基準的整體準確率在年度之間自約 12% 提升至 66.3%, 記憶架構為其中促成此一進展的關鍵之一; Nous Research 的 Hermes Agent 進一步提出四層級記憶分類——Procedural (SKILL.md)、Semantic (USER.md、MEMORY.md)、Episodic (sessions/ 配合 FTS5)、Working (作用中之上下文)——並能改善 LLM 智能體在跨任務情境下的可重用技能習得。

本研究將上述兩條主線整合為「Hermes-DQN」: 以開源 LLM (Gemma 4 31B) 撰寫獎勵函數; 以四層記憶架構 (Procedural / Semantic / Episodic / Working) 賦予其跨迭代學習能力; 並以感知 AST 之重播緩衝管理器抑制獎勵變動所引發之災難性遺忘 (catastrophic forgetting) (GB-DQN; Lee & Lee, 2025)。

開源 LLM 對獎勵設計流程之意義。封閉式 API 對 LLM-as-reward 管線而言至少帶來三項可重現性風險:(i) 供應商可在不通知使用者的情況下更新底層模型,使論文所報告之數值與後續重做之間失去可追溯之對應;(ii) 每次呼叫之延遲與費用會限制研究可負擔的種子數與迭代次數,而這恰恰是變異性導向 (variance-aware) 之研究方法所必須付出的代價;(iii) 離線或氣隙隔離 (air-gapped) 之部署情境 (工業控制、國防、設備端機器人) 無法將環境狀態送往外部服務。Gemma 4 31B 等開源權重模型可同時規避此三項風險。所付出的代價為其抽樣特性與 GPT-4 不同——而正如第 6 節所示,此一差異與獎勵稀疏度之間存在不易察覺的交互作用。

記憶機制之價值為何需要明確檢驗。在 LLM 智能體相關文獻中,記憶常被預設為「嚴格擴增」:更多脈絡、更多歷史範例、更多「情境內精進」(in-context refinement)。然而於 LLM-as-reward 設定下,「保留記憶 vs. 不保留記憶,其餘條件相同」之直接對比,尚未見諸具備統計報告之多環境系統性研究。主流敘事——更多迭代與更豐富之先驗將產生更佳之獎勵函數——雖屬合理,但屬於預設而非檢驗。本研究即補上此項檢驗。

本文之核心問題為:此一複合系統是否能在主流 DRL 基準任務上一致地改善獎勵設計;抑或 EUREKA 式作法本質上具有任務相依性?

實驗在 Gymnasium 之四個古典控制任務 (LunarLander-v3、CartPole-v1、MountainCar-v0、Acrobot-v1) 上進行,每環境 6 種條件、每條件 5 個種子,合計 120 次完整訓練。

全文路線。第 2 節整理 LLM 撰寫獎勵、記憶擴增之 LLM 智能體與重播緩衝管理三條相關文獻軸線。第 3 節說明三模組架構、閉環迭代流程、六項消融條件、四環境選擇,以及統計方法。第 4 節以四張表與四個分環境小節報告主要獎勵設計消融 (Part 1); 第 5 節報告一項補充性之 DQN 變體研究 (Part 2), 檢驗上述發現能否跨價值型智能體 (value-based agent) 遷移; 第 6 節討論反轉現象、深入分析一個具體失敗模式、刻畫變異性指紋,並列出限制與可證偽預測; 第 7 節作結。

本論文之四項貢獻 (語氣從嚴):

1. EUREKA 式之 LLM 獎勵撰寫流程被延伸至「開源 Gemma 4 31B」; 於本研究所測試之配置中,此一替代在稀疏獎勵任務上具有可行性。
2. 在密集獎勵之 LunarLander 上,跨迭代記憶機制與績效下降相關, $p=0.0317$ ——為此一脈絡下,首例達統計顯著之負向結果。
3. 一組變異性指紋 (variance signature) 被刻畫出來:Hermes 之表現與主任務之獎勵結構有關——物理簡單之稀疏任務上產出高度一致之智能體 ($\text{std}=3-4$), 塑形空間豐富之任務上則產出高變異之智能體 ($\text{std}=91+$)。
4. 「獎勵密度」(reward density) 被提出為判斷 LLM 獎勵設計與記憶擴增是否有益之候選預測指標。

2 Related Work

LLM 撰寫之獎勵設計。EUREKA (Ma et al., 2024) 結合 GPT-4 與類 CMA-ES 之搜尋機制撰寫獎勵函數,在 83% 的 Isaac Gym 任務上勝過人工基準,平均改善幅度約 52%。該設計仰賴封閉式商用 API 與 Isaac Gym 之連續控制套件,因此其作法能否延伸至開源權重模型、能否延伸至離散動作之古典控制,仍屬未定。Masadome 與 Harada (IEEJ 2025) 於 CartPole 上重現此一作法,並指出 LLM 撰寫之獎勵收斂速度快於手工調校之對照,但僅報告單一環境結果,且未單獨分離記憶之貢獻。CARD (Sun et al., 2024) 提出 Coder + Evaluator 框架,並結合軌跡偏好評估 (Trajectory Preference Evaluation),將獎勵生成與策略結果回饋串成閉環;惟其評估端本身為 LLM 評論員,而非實際 RL 智能體於原生獎勵下之回報。據作者所知,既有研究尚未透過「有記憶 vs. 無記憶」之直接比對,在多環境、多種子條件下單獨檢驗記憶機制之貢獻;本研究即補上此一比較。

記憶擴增之 LLM 智能體。Nous Research 之 Hermes Agent (2026) 提出四層級記憶分類——Procedural (SKILL.md)、Semantic (USER.md、MEMORY.md)、Episodic (sessions/ 配合 FTS5)、Working (作用中之上下文)——並回報於自主工作流程基準上跨任務技能習得改善。Stanford HAI 《AI Index 2026》報告指出 OSWorld 基準整體準確率在年度之間自約 12% 提升至 66.3%,記憶架構為其中促成此一進展

的關鍵之一 (Stanford HAI, 2026)。傳統之經驗重播變體 (如 Isele & Cosgun, AAAI 2018) 亦顯示選擇性保留之記憶可提升多任務學習表現; 惟此一脈絡之記憶層級為「狀態轉移」(transition) 而非「程式碼層級之獎勵函數」。LLM-as-author 脈絡下之既有記憶擴增研究多回報正向效應; 本文則似為首次於此設定下觀察到達統計顯著之負向效應。

非穩態獎勵下之重播緩衝管理。GB-DQN (Lee & Lee, 2025) 刻畫了獎勵變動所引發之 Bellman 算子漂移與災難性遺忘; 其解法為梯度增強之 DQN, 屬於價值函數面之改善。CHAIN 方法 (Tang & Berseth, 2024) 指出價值與策略 churn 之鏈鎖效應 (chain effect of value and policy churn) 會在目標分佈飄移時削弱學習穩定性。此二者皆與重播緩衝面之決策正交。本文提出之 AST 感知緩衝管理器 (KEEP / PARTIAL_KEEP / DECAY / CLEAR, 依獎勵 AST 相似度決策) 取緩衝面之視角, 其貢獻量化於第 4 節之消融結果。

獎勵塑形理論。Ng、Harada 與 Russell (1999) 證明: 勢能式 (potential-based) 之獎勵塑形可保持原 Markov 決策過程之最佳策略不變。此結論給出一個充分條件——塑形項須可表為「狀態勢能函數之差分」——在此條件下, 加入塑形之安全性可被形式化保證。本研究管線中由 LLM 撰寫之塑形並未被約束在勢能式子類別內, 此點亦為「記憶為何可能傷害績效」之一項原則性解釋: 多次迭代後之 LLM 獎勵會逐步偏離勢能式子類別, 因而無法保證仍保留原最佳策略。6.4 節將此點作為限制與後續工作再行討論。

DRL 基準任務。本研究採用 Gymnasium 之古典控制套件。近期一份 LunarLander DQN 研究 (Singh et al., 2025) 回報原生 DQN 於預設超參數下在 LunarLander-v2 達約 92% 成功率; 本研究於 v3 變體上採取類似設定。LLM-Explorer (Zhao et al., NeurIPS 2025) 則於 Atari 與 MuJoCo 上取得至多 +37.27% 之改善, 惟其作法為以 LLM 引導「探索」而非撰寫獎勵。相對於該工作, 本研究之主要差異在於針對「記憶機制」之跨環境消融深度。

3 Method

3.1 Architecture overview

Hermes-DQN 由三個耦合模組組成: Gemma 獎勵生成器、四層級記憶儲存, 以及感知 AST 之重播緩衝管理器。圖 1 整理三者之輸入、輸出與閉環資料流。




圖 1: 系統架構: Gemma 獎勵生成器、四層級記憶與 AST 緩衝管理之資料流。

三模組之介面分別如下。

1. 獎勵生成器 (Gemma 4 31B)。

- 輸入: (a) 環境任務規格 (觀測索引、動作語意、原生獎勵結構); (b) 可選之「PRIOR HIGH-FITNESS ATTEMPTS」區塊, 其內容為長期記憶中依適應度排序之前 k 筆嘗試與其分數; (c) 回應格式約束 (函數簽章、僅允許決定性 Python、禁止網路與檔案 I/O)。
- 輸出: reward(obs, action, next_obs, env_reward, terminated, truncated, info) 之 Python 源碼, 須通過語法良構與簽章對齊之驗證方可使用。

- 內部狀態: 呼叫之間無狀態; 所有跨迭代訊息皆透過記憶區塊傳入。
2. 四層級記憶。依 Hermes Agent 之分類——Procedural (SKILL.md)、Semantic (USER.md 與 MEMORY.md)、Episodic (sessions/ 配合 FTS5)、Working (作用中之上下文)——每完成一次訓練迭代, 即寫入一筆紀錄, 內含獎勵原始碼、SHA-256、以及以原生獎勵衡量之適應度指標。Episodic 層保存逐迭代紀錄; Working 層則保存將被組裝為提示之 top-k 取回結果。讀取查詢以原生適應度為主排序, 以時間先後解決平手。記憶模組對訓練之唯一副作用, 即下一輪生成器所見之「先前嘗試」區塊。
 3. AST 感知之重播緩衝管理器。透過 Python ast 模組分別解析新舊獎勵原始碼, 並將結構差異歸類為 IDENTICAL、SIGNATURE_ONLY (簽章不變、函式體變動)、STRUCTURAL_DIFF (控制流變動但多數運算元延續)、TOTAL_REWRITE (結構幾無重疊) 四類。此分類結果決定性地對應至 KEEP (完整保留)、PARTIAL_KEEP (依終止旗標與獎勵符號謂詞篩選保留)、DECAY (對每筆樣本套用 0.5 權重後保留)、CLEAR (清空緩衝重新累積) 四種策略之一。分類器與策略查表皆為兩個原始碼字串之純函數。

3.2 Closed-loop iteration

對於每一組 (環境、條件、種子), 閉環會執行 5 次以下迭代:

1. `memory.top_k_by_fitness(k=5) → priors`
2. `Gemma.generate(task_spec, memory=priors) → reward_src`
3. `AST.diff(prev_reward_src, reward_src) → diff_kind`
4. `buffer_policy = decide(diff_kind); apply(prev_buffer, buffer_policy)`
5. `DQN.train(reward_src, buffer, episodes=N) → trained_model`
6. `eval_env_native(model, n=100 unseen seeds) → fitness`
7. `memory.write(reward_src, fitness)`

逐步以白話翻譯: 第 1 步從歷史中取出表現最佳之過往嘗試; 第 2 步請 LLM 寫出可能與過往不同之新獎勵函數; 第 3 步在語法樹層面量測「變了多少」; 第 4 步依此飄移程度決定是否要保留先前的經驗回放; 第 5 步以新獎勵訓練一個全新 DQN 策略; 第 6 步以環境原生 (未經塑形) 獎勵在另一組不相交種子上評估, 以維持條件之間的可比性; 第 7 步將新出之 (原始碼, 適應度) 寫回記憶以供下一輪取用。第 6 步固定採用「100 個未見種子 (10000–10099) × 環境原生獎勵」之設定, 不論訓練條件為何; 這是跨條件唯一公平之衡量基準, 因塑形獎勵會在條件之間及迭代之間變動。

3.3 Six conditions

依 DRL 領域之標準消融研究實務 (Henderson et al., 2018), 共設計六種條件:

編號	獎勵來源	記憶	AST 緩衝	迭代次數
B0-env-native	環境原生獎勵	—	—	1
B1-handcrafted	人工撰寫	—	—	1
B2-gemma-oneshot	單次 Gemma 呼叫	∅	∅	1
B3-hermes-full	Gemma + 記憶	✓	✓	5
B3-no-memory	每次迭代重新呼叫 Gemma	∅	✓	5
B3-no-AST	Gemma + 記憶, 無 AST 管理	✓	∅	5

各條件分別檢驗不同假設。B0 為每個環境建立「無塑形」之基準; B1 檢驗合理人工塑形是否已足夠, 故任何 LLM 貢獻必須同時勝過 B0 與 B1; B2 檢驗單次 Gemma 呼叫是否已足以攫取大部分增益 (即「記憶是否必要」之問題); B3-hermes-full 為完整提案系統; B3-no-memory 以「每輪重新呼叫

Gemma 而不提供歷史」進行 5 輪迭代, 在相同預算下分離出記憶機制本身之貢獻; **B3-no-AST** 保留記憶但停用 AST 緩衝決策 (緩衝固定為 KEEP), 分離緩衝管理之貢獻。B3 系列條件執行 5 次閉環迭代; B0/B1/B2 僅執行單次訓練, 以對應典型使用者首次嘗試之工作量。

3.4 Environment selection

實驗挑選了 Gymnasium 四個古典控制環境, 涵蓋「獎勵密度」之兩端極值:

環境	獎勵類型	觀測維度	動作數	「解題」門檻
LunarLander-v3	密集 (連續塑形)	8	4	mean $\geq$ 200
CartPole-v1	稀疏 (+1/存活步)	4	2	mean $\geq$ 475
MountainCar-v0	稀疏 (-1/步)	2	3	mean $\geq$ -110
Acrobot-v1	稀疏 (-1/步)	6	3	mean $\geq$ -100

選擇此四環境之理由有三。其一是獎勵密度之多樣性: 一個密集、三個稀疏之組合可在不改動其他變數下同時探討兩種獎勵情境。其二是可重現性: 古典控制任務具備已知之最佳策略, 且可於單張 GPU 上經濟地運行, 使 5 種子 $\times$ 6 條件 $\times$ 4 環境 = 120 次完整訓練成為可行規模。其三是動作空間之多樣性: 離散動作數涵蓋 2、3、4 三種, 可降低「獎勵密度效應」被誤判為「動作空間大小效應」之混淆風險。

3.5 Statistical methodology

- 主要指標: env_native_mean——以原生 (未經塑形) 獎勵在 100 個評估種子上之平均回報。
- 檢定方法: 雙尾 Mann-Whitney U 檢定 ($\alpha=0.05$)。
- 信賴區間: Bootstrap 法, 5000 次再抽樣, 95% 信賴水準。
- 「勝出」判準 (三條件變體, 參考自 Henderson et al., 2018): 需同時滿足三條件—— $p < 0.05$ 、 $|\Delta \text{mean}|/|\text{baseline}| \geq 10\%$ 、信賴區間不重疊。
- 種子保留: 每組條件保留全部 5 個種子, 不剔除任何發散種子。需注意 Acrobot 之 B0 與 B1 條件中有 1–2 個崩潰種子 (env_native_mean ≤ -200) 並未剔除, 此舉膨脹其變異數, 並進而擴大其 Bootstrap 信賴區間。

於 $n=5$ 此一規模下選擇 Mann-Whitney U 與 Bootstrap 之理由, 值得簡短說明。在小樣本下, 參數檢定 (如 Student's t) 預設樣本近似常態分佈——此一假設僅以 5 個觀測值無從驗證, 且對「一兩個種子發散」所造成之重尾分佈相當敏感。Mann-Whitney U 為非參數、僅依秩、於 $n=5$ 表現穩定之檢定方法, 代價為相對於正確指定之參數檢定統計力較低。Bootstrap 同樣不需分佈假設, 而 5000 次再抽樣對 95% 區間於此樣本規模而言已屬充分。6.4 節將此一統計力限制明確列出: 本研究僅對大效應 (Cohen's $d \geq 1$) 具備穩定偵測能力。

4 Experiments — Part 1: Reward-Design Ablation

4.1 Setup

項目	內容
硬體	NVIDIA RTX 4090 $\times$ 1、Windows 11、CUDA 12.1
Python / PyTorch	3.11 / 2.5.1
DQN	64 $\times$ 64 MLP、lr=5e-4、 $\gamma=0.99$ 、batch=64、 ϵ 於 50K 步內線性衰減、目標網路每 1000 步更新、replay 容量 100K
隨機種子	訓練: 42、43、44、45、46; 評估: 10000–10099 (與訓練種子完全互斥)

項目	內容
總訓練次數	120 次 (4 環境 × 6 條件 × 5 種子)

4.2 Results

表 1: 跨環境總表 (env_native_mean, n=5; 粗體代表相對 B0 之顯著勝出; 斜體代表相對 B3-no-memory 之顯著敗退)

條件	LunarLander	CartPole	MountainCar	Acrobot
B0-env-native	173.22	154.80	-193.44	-194.96
B1-handcrafted	77.77	160.19	-140.40	-185.28
B2-gemma-oneshot	152.65	187.64	-153.09	-83.21
B3-hermes-full	<i>153.56</i>	334.44	-132.53	-82.92
B3-no-memory	248.77	243.21	-168.55	-83.23
B3-no-AST	95.42	220.81	-134.59	-83.58




圖 2: CartPole 全六條件之逐種子箱型圖; B3-hermes-full 中位數最高但四分位距較寬。

表 2: B3-hermes-full vs B0-env-native (主要假設驗證)

環境	Hermes 平均	B0 平均	Δ	p	判定
LunarLander (密集)	153.56	173.22	-11.4%	1.0000	n.s.
CartPole (稀疏)	334.44	154.80	+116.1%	0.0317	WIN
MountainCar (稀疏)	-132.53	-193.44	+31.5%	0.0112	WIN
Acrobot (稀疏)	-82.92	-194.96	+57.5%	0.0952	近 WIN




圖 3: 跨環境主結果: B3-hermes-full 與 B0-env-native 之百分比差距; 稀疏正向、密集負向。

表 3:B3-hermes-full vs B3-no-memory (記憶效應)

環境	Hermes 平均	NoMem 平均	Δ	p	方向
LunarLander (密集)	153.56	248.77	-38.3%	0.0317	記憶有害
CartPole (稀疏)	334.44	243.21	+37.5%	0.2222	有助 (n.s.)
MountainCar (稀疏)	-132.53	-168.55	+21.4%	0.1425	有助 (n.s.)
Acrobot (稀疏)	-82.92	-83.23	+0.4%	0.7533	無效應

表 4:B3-hermes-full 之變異性指紋

環境	平均	標準差	範圍	詮釋
LunarLander	153.56	91.40	[11.60, 252.40]	高變異; 出現一個近零種子
CartPole	334.44	113.18	[175.23, 485.23]	高變異, 惟皆為正
MountainCar	-132.53	3.08	[-135.87, -129.38]	極端一致
Acrobot	-82.92	4.39	[-89.98, -78.62]	高度穩定

4.3 LunarLander-v3 (dense reward)

LunarLander 是本研究中唯一的密集獎勵環境, 亦是唯一原生獎勵已足以提供有效學習訊號之環境。B0-env-native 取得 173.22 之平均回報, 接近官方「解題」門檻 200。此一情境因而成為「在已具備充分訊號之獎勵上再加上 LLM 塑形」之自然壓力測試。表 2 顯示 B3-hermes-full (153.56) 與 B0 (173.22) 在統計上無差異 ($p=1.0000$)。表 3 之對比更具揭示性:B3-no-memory 達 248.77, 已超過解題門檻; 而 B3-hermes-full 反而下降至 153.56 ($p=0.0317$ 、 -38.3%)。於此一配置下, 記憶機制與顯著之績效下降相關。每種子變異亦印證此一觀察:B3-hermes-full 之 $\text{std}=91.40$, 並含一個僅 11.60 之近零種子 (詳見圖 3 及 6.2 節對 `seed_43` 之討論); 相較之下 B3-no-memory 之 $\text{std}=14.66$ 。

4.4 CartPole-v1 (sparse, +1 per alive step)

CartPole 為教科書級之稀疏獎勵任務, 具明確之上限 (v1 上限為 500)。B0-env-native 之 154.80 遠未達上限; 單純「每存活步 +1」之訊號太弱, 原生 DQN 在訓練預算內難以穩定解出。B3-hermes-full 取得 334.44 (相對 B0 +116.1%、 $p=0.0317$), 為本研究全表中相對增幅最大之結果。此一勝出為真, 但變異亦大: $\text{std}=113.18$ 、範圍 [175.23, 485.23]。圖 6 之箱型圖呈現各條件之分佈樣態,B3-hermes-full 相對於 B0、B1、B2 之上拉同時來自「中位數上移」與「尾部變寬」。CartPole 因此成為本研究中最清楚之示例:LLM 撰寫之獎勵塑形確實能解鎖一個原生 DQN 在 100 個評估種子下無法穩定解出之任務。

4.5 MountainCar-v0 (sparse, -1 per step)

MountainCar 展現本研究中最緊湊之變異指紋:B3-hermes-full 五個種子之 $\text{std}=3.08$, 全部落於範圍 [-135.87, -129.38] 之內。B3-hermes-full 取得 -132.53 (相對 B0=-193.44 為 +31.5%、 $p=0.0112$), 五個種子幾乎收斂至同一數值。Gemma 在此環境上撰寫之「每步 +0.5 動量塑形」與文獻中常見之經典手工塑形相當接近, 此一觀察與「單一目標任務允許接近最佳之塑形, 而 LLM 能可靠地找出」之假設一致。圖 5 將 MountainCar 與 LunarLander 之逐迭代軌跡並列呈現, 構成兩種獎勵情境下「穩定 vs. 混沌」之對比。

4.6 Acrobot-v1 (sparse, -1 per step)

Acrobot 是未能通過嚴格勝出判準之案例。B3-hermes-full 取得 -82.92 相對 B0=-194.96 ($\Delta=+57.5\%$), 但 Mann-Whitney 之 p 為 0.0952——效應方向明確、效應量亦大, 但未通過 $\alpha=0.05$ 之門檻。B0 五個

種子中有兩個發散至 $\text{env_native_mean} \leq -200$, 膨脹其變異與 Bootstrap 區間; 此屬 3.5 節「種子保留」原則所預期之情形之一。B2-gemma-oneshot (-83.21) 與 B3-no-memory (-83.23) 均與 B3-hermes-full 相當接近, 顯示於 Acrobot 上任何合理之 LLM 撰寫塑形皆已足夠, 記憶機制之邊際貢獻有限。變異亦低 ($\text{std}=4.39$), 與 MountainCar 之穩定樣態一致。

4.7 Cross-environment synthesis

整體觀之, 表 2 至表 4 描繪出一致而連貫之樣態。三個稀疏環境構成一族: B3-hermes-full 相對 B0 之增幅介於 +31.5% 至 +116.1%、記憶效應幅度小且不顯著、每種子變異普遍偏低 (MountainCar 與 Acrobot 之 $\text{std} \leq 4.4$, CartPole 之 $\text{std}=113.18$ 為唯一例外)。密集環境則單獨自成一族: B3-hermes-full 與 B0 統計上無差異、記憶效應幅度大且達顯著之負向、每種子變異高 ($\text{std}=91.40$)。將兩族明確分隔之維度為獎勵密度。需注意者, 在本四環境面板中, 「塑形空間 (豐富 vs. 貧乏)」與「獎勵密度 (密集 vs. 稀疏)」呈現部分混淆——LunarLander 與 CartPole 皆屬塑形空間豐富, 但僅 LunarLander 為密集; 6.4 節將此點列為限制, 並指出後續加入 LunarLanderContinuous 可協助分離兩變數。

5 Experiments — Part 2: DQN-Variant Generalization

5.1 Motivation and setup

Part 1 全程採用原生 DQN (vanilla DQN; Mnih et al., 2015)。Part 2 則檢驗獎勵設計之貢獻能否遷移至更先進之價值型智能體 (value-based agent)。本實驗之設計為: 固定獎勵管線——僅比較 B0-env-native 與 B3-hermes-full——並在三種 DQN 變體之間切換: vanilla (沿用 Part 1 之基準)、Double DQN (van Hasselt et al., 2016) 與 Dueling DQN (Wang et al., 2016)。四個環境皆納入評估, 每格 $n=5$ 個種子, 採與 Part 1 相同之評估協定 (100 個未見種子、環境原生回報)。

Double DQN 將動作選擇 (由線上網路 online network 負責) 與價值評估 (由目標網路 target network 負責) 解耦, 藉此降低標準 DQN 目標值之最大化偏誤 (maximization bias)。Dueling DQN 則將 Q 網路拆解為狀態價值串流 (state-value stream) $V(s)$ 與優勢串流 (advantage stream) $A(s,a)$, 再以 $Q = V + (A - \text{mean}(A))$ 重組。此二變體實作了 Rainbow 七項組件中之兩項; 其餘組件留待 Future Work 處理。

5.2 Results — Hermes vs baseline across variants




圖 4: 圖 7。Part 2 主結果: 三種 DQN 變體、四個環境下之 B3-hermes-full 對 B0-env-native。MountainCar 在三種變體下皆呈現 Hermes 勝出; LunarLander 在任一變體下皆未勝出。

表 5: Part 2——B3-hermes-full vs B0-env-native (每格 $n=5$)

環境	變體	B0 平均	Hermes 平均	Δ	p	判定
LunarLander (密集)	vanilla	173.22	153.56	-11.4%	1.0000	n.s.
LunarLander (密集)	Double	171.90	131.68	-23.4%	1.0000	n.s.
LunarLander (密集)	Dueling	166.86	137.98	-17.3%	0.6905	n.s.
CartPole (稀疏)	vanilla	154.80	334.44	+116.1%	0.0317	WIN
CartPole (稀疏)	Double	182.13	388.60	+113.4%	0.1508	n.s.

環境	變體	B0 平均	Hermes 平均	Δ	p	判定
CartPole (稀疏)	Dueling	227.22	315.99	+39.1%	0.2492	n.s.
MountainCar (稀疏)	vanilla	-193.44	-132.53	+31.5%	0.0112	WIN
MountainCar (稀疏)	Double	-195.16	-134.74	+31.0%	0.0097	WIN
MountainCar (稀疏)	Dueling	-198.70	-146.89	+26.1%	0.0449	WIN
Acrobot (稀疏)	vanilla	-194.96	-82.92	+57.5%	0.0952	n.s.
Acrobot (稀疏)	Double	-233.82	-81.17	+65.3%	0.4206	n.s.
Acrobot (稀疏)	Dueling	-103.79	-80.05	+22.9%	0.0556	n.s.

在三個稀疏獎勵環境上,B3-hermes-full 於三種變體下皆於方向上勝過 B0 (9/9 個稀疏格皆為正)。MountainCar 在三種變體下皆達統計顯著 ($p < 0.05$); CartPole 與 Acrobot 雖方向明確, 惟其 p 值因 B0 高變異而被膨脹 (例如 Acrobot 之 B0 std 高達 211)。

在密集獎勵環境 (LunarLander) 上,B3-hermes-full 於三種變體下皆低於 B0 (-11% 至 -23%), 且無任一比較達顯著。此一結果於所有被測試之智能體上重現了 Part 1 之發現 (記憶於密集獎勵上與績效下降相關)。

5.3 Hermes robustness across variants




圖 5: 圖 8。各環境下 B3-hermes-full 於三種 DQN 變體之平均; 環境內之差異未達統計顯著。

表 6: B3-hermes-full 各變體平均 + 兩兩 Mann-Whitney U p 值

環境	vanilla	Double	Dueling	V-vs-Db p	V-vs-Du p	Db-vs-Du p
CartPole	334.44	388.60	315.99	0.548	0.841	0.548
MountainCar	-132.53	-134.74	-146.89	1.000	1.000	0.841
Acrobot	-82.92	-81.17	-80.05	0.690	0.310	0.548
LunarLander	153.56	131.68	137.98	1.000	0.841	0.841

於每個環境內,B3-hermes-full 在三種 DQN 變體之間之任一兩兩比較皆未達統計顯著 (所有 $p > 0.3$)。因此, 獎勵設計之貢獻於所測試之價值型智能體之間, 大致與智能體之選擇正交 (orthogonal)。

由此可引出兩項較為細微之觀察。其一, 先進智能體會部分吸收稀疏獎勵之塑形。於 CartPole 上,Dueling 之基準 B0 達 227.22, 為所有變體中最高之 B0 (vanilla 為 154.80); 於 Acrobot 上,Dueling 之基準達 -103.79 (vanilla 為 -194.96, std 由 179 降至 42)。Dueling 之 V/A 分解提供了一項歸納偏置 (inductive bias), 縮小了原本由 Hermes 填補之落差。

其二, 變異性指紋不僅與環境相依, 亦與智能體相依。於 MountainCar 上,B3-hermes-full 之逐種子 std 由 3.08 (vanilla) 上升至 17.04 (Double)、再至 32.35 (Dueling)——Part 1 之「極度穩定」指紋, 實為該環境上 vanilla 智能體所特有。

6 Discussion

6.1 Sparse-reward tasks benefit from LLM authorship

CartPole、MountainCar、Acrobot 三者之原生獎勵幾乎不具學習訊號（僅為二元存活訊號或固定時間懲罰）。在本研究之訓練預算內，原生獎勵下之 DQN 幾乎無法穩定解出任何一者（B0 之成功率分別為 0%、0%、62%）。任何合理之塑形皆能解鎖學習——即使是 Gemma 一次性嘗試（B2-gemma-oneshot）亦能回收大部分落差。Hermes 之完整流程則更進一步提升一致性：於 MountainCar 上，B3-hermes-full 之五個種子皆收斂至極為接近之表現（std=3.08，範圍 [-135.87, -129.38]）。

三項補充觀察可進一步刻畫此一現象。一項觀察為：B2-gemma-oneshot 與 B3-hermes-full 在三稀疏環境上之差距並不大（CartPole: 187.64 → 334.44; MountainCar: -153.09 → -132.53; Acrobot: -83.21 → -82.92），且 Acrobot 上幾近於零；記憶之貢獻於「單次塑形已不佳」之 CartPole 較大，於「單次塑形已佳」之 Acrobot 反而趨於零。第二項觀察為：B3-no-AST（CartPole 220.81、MountainCar -134.59、Acrobot -83.58）於兩個動量類稀疏環境上與 B3-hermes-full 噪音內等同，顯示 AST 緩衝機制之貢獻主要落在塑形空間豐富之 CartPole。最後，B1-handcrafted 一欄在四環境中三者具有競爭力，意即 LLM 撰寫之增益並非單純「有塑形 vs. 無塑形」之效應，而是「有塑形 vs. 良好塑形」之效應。

6.2 Dense-reward tasks: memory is associated with reduced performance

LunarLander 之原生獎勵已內含豐富之梯度資訊（位置、速度、姿態角、起落架接觸、燃料消耗）。在此情境下，加入 LLM 撰寫之塑形項充其量只是中性（B3-hermes-full ≈ B0, $p=1.00$ ）。記憶機制本身則與績效下降相關：B3-no-memory 取得平均 248.77（std=14.66）；B3-hermes-full 取得平均 153.56（std=91.40）； $p=0.0317$ 。Part 2 之變體研究（第 5 節）進一步確認：此一「密集 vs. 稀疏」之樣態於三種被測試之智能體上皆成立——於 vanilla、Double 與 Dueling DQN 下，Hermes 皆於密集之 LunarLander 落後於 B0，而於三個稀疏環境領先。




圖 6: 四環境之記憶效應 (Hermes - no-memory) / |no-memory| %; 僅 LunarLander 達統計顯著。

可運作之假設為：在密集獎勵下，將高適應度之歷史範例提供給 LLM，會使其偏向加上額外塑形項，進而與原生梯度產生衝突。在稀疏獎勵任務中，「錨點」是「DQN 連解都解不開」，因此記憶帶來之改進壓力被引導為精修；在密集獎勵任務中，「錨點」本已強烈，改進壓力反而轉化為干擾。此一敘事與 Ng 等 (1999) 之勢能式塑形定理一致：多次迭代之 LLM 獎勵會偏離可形式化保證保留最佳策略之勢能式子類別，而此偏離之代價在原生獎勵已具足夠訊號時最為明顯。

進一步檢視 B3-hermes-full 在 LunarLander 上之五個種子，其表現分別為 {252.4, 11.6, 125.0, 196.7, 182.0}。其中一個種子 (seed_43) 之 env_native_mean 僅 11.60，意即訓練出一個「懸停而不著陸」之退化策略。seed_43 之 iter_05 獎勵原始碼與上述假設一致。其塑形項包含一項近地時對垂直速度之強懲罰 ($-0.4 \times |v_y|$ ，當 $y < 0.5$)，搭配對腳部接觸之連續獎勵 ($+0.5 \times$ 接地腳數)。兩者合計可能引導智能體於近地低空持續滯空、雙腳輕觸地面，而非完成最終降落以獲取終端著陸獎勵。本研究並未對此機制進行形式化診斷，此一個別種子僅屬軼事性 (anecdotal) 證據。

6.3 Variance signature

B3-hermes-full 之種子間標準差在四個環境之間相差超過一個數量級 (3.08 至 113.18): Mountain-Car 之 3.08、Acrobot 之 4.39、LunarLander 之 91.40, 以及 CartPole 之 113.18。前兩個近乎收斂之環境共享三項特性:(a) 稀疏之 $-1/\text{step}$ 獎勵;(b) 簡單之二維或三維動力學;(c) 單一明確之子目標 (累積動量 / 注入能量)。一個合理之解讀為: 於此類單一目標任務上, Gemma 會收斂至近似最佳之塑形, LLM 隨機抽樣所能引入之變異空間相當有限。




圖 7: B3-hermes-full 之逐種子變異性指紋; 稀疏簡單環境緊密, 塑形豐富環境分散。

LunarLander 之高變異恰由相反性質引發: 豐富之塑形空間使「合理」獎勵設計多元並存, 其中部分會與原生獎勵以不易察覺之方式互相衝突。種子間之單一崩潰 ($\text{env_native_mean}=11.60$) 即反映出 Gemma 寫入之塑形項將 DQN 之學習軌跡推離環境原本的最佳解。圖 5 以「一個 LunarLander 代表種子 vs. 一個 MountainCar 代表種子」之逐迭代 env-native 回報並列呈現: LunarLander 之軌跡在 5 次迭代之間反覆震盪, MountainCar 之軌跡則單調上升, 以視覺方式重述「混沌 vs. 穩定」之對比。




圖 8: 逐迭代軌跡: LunarLander 代表種子 (混沌) 對比 MountainCar 代表種子 (單調)。

6.4 Limitations

- 小樣本規模。n=5 僅對大效應 (Cohen's $d \geq 1$) 具備充足統計力; 對中等效應 ($d \approx 0.5$) 而言, 於此樣本規模下幾乎難以得出定論。表 3 中數項對比 (CP、MC 之記憶效應) 方向明確但因樣本不足而無法定論。我們將以 n=10 或 n=20 之重做列為後續工作之首要項目。
- B1-handcrafted** 為暫時版本。B1 之獎勵函式由本研究作者本人撰寫, 因此任何依賴「人工塑形優於 LLM 塑形」之比較, 僅憑此資料無法完整支撐。理想狀況需要由非作者之第三方撰寫人工塑形基準, 方能讓相關對比承擔完整重量。本文中 B1 僅用以確立「簡單塑形於各環境上至少可行」, 並非作為決定性之人類基準。第 7 節之主要結論建立於 B0、B3-hermes-full 與 B3-no-memory 之上; 在此將 B1 之佔位性質列為一項限制, 以免下游讀者過度解讀表 1 之 B1 一欄。
- 變異性指紋目前由二環境而非四環境完整刻畫。CartPole 與 LunarLander 皆具豐富塑形空間且皆呈現高變異, 但前者為稀疏、後者為密集, 二者並非完全可比。後續若引入「密集獎勵 × 簡單物理」之環境 (如 LunarLanderContinuous), 將有助於釐清「塑形空間」與「獎勵密度」二者之

分離效應。

- 僅採用單一 **LLM (Gemma 4 31B)**。所觀察之變異性可能與此一模型之抽樣特性有關。後續以 Llama 3.3、Qwen 3、DeepSeek-V3 等之重做為自然延伸。
- 僅涵蓋部分 **Rainbow** 組件。本研究實作了 Rainbow 七項組件中之兩項 (Double DQN 與 Dueling 架構)。其餘組件——優先經驗重播 (Prioritized Experience Replay)、多步回報 (Multi-Step returns)、噪聲網路 (Noisy Networks), 以及分佈式 Q 學習 (Distributional Q-learning; C51 / QR-DQN), 以及其完整 Rainbow 組合——皆留待後續工作。其實作複雜度 (約 500 行程式碼) 及其與獎勵設計貢獻之正交性, 使其落於本研究範圍之外。
- 未進行獎勵正確性分析。本研究並未形式化檢驗 Gemma 所撰寫獎勵是否與最佳價值函數對齊。後續可結合 Ng et al. (1999) 之獎勵塑形定理, 進行形式化驗證——例如自動將 LLM 撰寫之獎勵投影至勢能式子類別, 並量測每次迭代被加入之「非勢能式」質量。

6.5 Falsifiable predictions

依本研究發現, 以下三項可證偽假設值得提出:

1. 原生獎勵雖密集但對齊不佳之任務, 將自記憶機制中獲益, 因 Hermes 可透過迭代修正一次性 LLM 難以察覺之錯位。
2. 獎勵密度單獨將不足以作為預測指標, 因其與任務複雜度之交互作用亦屬關鍵; 預期所需之分類應為二維空間——(稀疏 vs. 密集) $\times$ (塑形空間豐富 vs. 貧乏)。
3. 更強之 **LLM (如 Gemini 2.5 Pro)** 將加劇變異性指紋, 因能力更強之 LLM 傾向產出更具侵略性之塑形, 同時推高高端表現與崩潰風險。

7 Conclusion

本文於 Gymnasium 四個古典控制環境上系統性評估 Hermes-DQN——一個結合開源 LLM 獎勵作者、跨迭代記憶與 AST 感知重播緩衝之複合系統。於三個被測試之稀疏獎勵環境中, B3-hermes-full 之平均表現皆高於原生 DQN, 其中 2/3 達統計顯著 (CartPole $p=0.03$ 、MountainCar $p=0.01$), 第三者 (Acrobot $p=0.095$) 方向明確但未通過嚴格三條件勝出判準。此一結果與「EUREKA 式之 LLM 獎勵設計可遷移至開源模型」之假設一致 (限於稀疏情境)。然而在唯一之密集獎勵環境 (LunarLander) 上, Hermes 與基準在統計上無差異, 且跨迭代記憶機制與績效下降相關 ($p=0.0317$ 、 -38%)。一組變異性指紋伴隨此一反轉出現: 於本評估中, Hermes 於物理簡單之稀疏環境上極度穩定 ($\text{std} \leq 5$), 於塑形空間豐富之環境上則為高變異 ($\text{std}=91+$), 並偶有近乎崩潰之種子。在所測試之配置下, 獎勵密度似可作為 LLM 獎勵設計適用性之預測指標; 記憶機制應依任務「選擇性啟用」而非預設開啟。

References

1. Ma, Y. J., Liang, W., Wang, G., Huang, D.-A., Bastani, O., Jayaraman, D., Zhu, Y., Fan, L., & Anandkumar, A. (2024). **Eureka: Human-level reward design via coding large language models**. ICLR 2024.
2. Cardenoso, F., & Caarls, W. (2025). **Leveraging LLMs for reward function design in reinforcement learning control tasks**. arXiv:2511.19355.
3. Sun, S., Liu, R., Lyu, J., Yang, J.-W., Zhang, L., & Li, X. (2024). **A Large Language Model-Driven Reward Design Framework via Dynamic Feedback for Reinforcement Learning**. arXiv:2410.14660.
4. Lee, C.-H., & Lee, C. (2025). **GB-DQN: Gradient Boosted DQN Models for Non-stationary Reinforcement Learning**. arXiv:2512.17034.
5. Isele, D., & Cosgun, A. (2018). **Selective Experience Replay for Lifelong Learning**. AAAI 2018.

6. Zhao, X., et al. (2025). **LLM-Explorer: Curiosity-driven exploration with language models.** NeurIPS 2025.
7. Masadome, R., & Harada, T. (2025). **LLM-driven reward design for cart-pole stabilization.** IEEJ Transactions.
8. Nous Research. (2026). **Hermes Agent: 4-tier hierarchical memory for autonomous LLM workflows.** Technical Report.
9. Tang, H., & Berseth, G. (2024). **Improving Deep Reinforcement Learning by Reducing the Chain Effect of Value and Policy Churn.** NeurIPS 2024.
10. Stanford HAI. (2026). **Artificial Intelligence Index Report 2026.**
11. Singh, A., Patel, R., et al. (2025). **Lunar Lander: Deep Q-Learning Approach.** International Journal of Recent Publications and Reviews, 6(5), IJRPR45485.
12. Henderson, P., Islam, R., Bachman, P., Pineau, J., Precup, D., & Meger, D. (2018). **Deep Reinforcement Learning that Matters.** AAAI 2018.
13. Ng, A. Y., Harada, D., & Russell, S. (1999). **Policy invariance under reward transformations: Theory and application to reward shaping.** ICML 1999.
14. Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., et al. (2015). **Human-level control through deep reinforcement learning.** Nature, 518(7540), 529–533.
15. van Hasselt, H., Guez, A., & Silver, D. (2016). **Deep Reinforcement Learning with Double Q-learning.** AAAI 2016.
16. Wang, Z., Schaul, T., Hessel, M., van Hasselt, H., Lanctot, M., & de Freitas, N. (2016). **Dueling Network Architectures for Deep Reinforcement Learning.** ICML 2016.

Appendix A. Reproducibility

本研究之所有實驗產出皆公開於 https://github.com/oomao/Final_project_Group5_DRL:

- 原始碼:hermes_dqn/
- 編排器:scripts/run_full_experiment.py
- 每次訓練之設定與獎勵原始碼:runs/final*/
- 各環境比對報告:reports/final*/comparison_report.md
- 跨環境整合分析:reports/integration/4env_integration.md

每一個訓練目錄皆包含:config.json (超參數 + env_id + reward_fn_sha256)、episodes.jsonl (逐集回報)、reward_fn.py (Gemma 所撰寫之獎勵函數, 或 B0/B1 之原始碼)、model_final.pt (最終 DQN 權重)、llm_attempts.jsonl (Gemma 之提示與回應紀錄, 已移除可識別資訊)。