

五個章節 · FIVE CHAPTERS

本報告的脈絡

從研究動機出發，依序走過相關研究、系統方法、實驗結果，收束於結論。

1	研究動機	MOTIVATION
2	相關研究	RELATED WORKS
3	系統方法	PROPOSED METHOD
4	實驗結果	EXPERIMENTAL RESULTS
5	結論	CONCLUSION

A SPARSE · 稀疏獎勵

只在「成功」那一刻給訊號，中間幾乎全是 0。探索訊號太弱，agent 常常學不動。

- 回饋稀少 → 樣本效率低
- 許多任務在預算內無法收斂

B DENSE · 人工塑形

手工 reward shaping 雖能加速，卻把人的偏見寫進目標，且難以擴展到新任務。

- 每個環境都要重寫、調參
- 易塑形出「似是而非」的代理目標

兩端都不理想 → 能不能讓機器自動寫出好的獎勵函數？

LLM 寫獎勵可行， 但能普遍有效嗎？

- ICLR 2024 **+52%** EUREKA^[1]：用 GPT-4 寫獎勵，83% 任務勝人類、平均 +52%。
- 延伸 ① **OSS** 開源化：換開源 LLM 取代 GPT-4，省成本、可重現。
- 延伸 ② **MEM** 記憶化：跨輪累積，refine 過往的獎勵設計經驗。
- 延伸 ③ **BUF** 緩衝穩定：獎勵一變、舊樣本失效，需處理 replay buffer。

研究問題 RQ 三者**同時**解決後，LLM 自動獎勵設計能否**普遍有效**？

[1] Ma et al., EUREKA, ICLR 2024

用 LLM 撰寫獎勵 · LLM-AS-REWARD-AUTHOR

方法	核 心 模 型	跨 輪 記 憶	BUFFER 處 理
EUREKA ^[1] ICLR 2024	GPT-4 (閉 源)	演化式 in-context	未處理
CARD ^[2] 2024	LLM coder + critic	回饋迴圈	未聚焦
LEARN-Opt ^[3] 2025	開源 LLM	無顯式記憶	未聚焦

既有路線各自處理「模型／記憶」，但**沒有一條**正面處理「獎勵改變後的 replay buffer」。

缺口 • BUFFER-SIDE

[1] EUREKA, ICLR 2024 [2] Sun et al., CARD, 2024 [3] Cardenoso & Carls, LEARN-Opt, 2025

記憶智能體 · 非穩態 BUFFER · 研究缺口

三個領域交會，*尚未整合驗證*

RESEARCH GAP

3 × 0

三條線交會處，**零**整合驗證。本研究從 **buffer-side (AST)** 切入，正交互補。

- ① LLM 寫獎勵：缺跨輪記憶、不處理 buffer
- ② 記憶機制：DRL 多任務缺實證
- ③ buffer 端遺忘：未被處理

①

記憶智能體 Memory Agents

Nous Hermes 四層記憶^[4]；OSWorld 12% → 66.3%^[5]。

②

非穩態 Replay Buffer

GB-DQN 走 value-side^[6]；CHAIN 處理 churn^[7]。

③

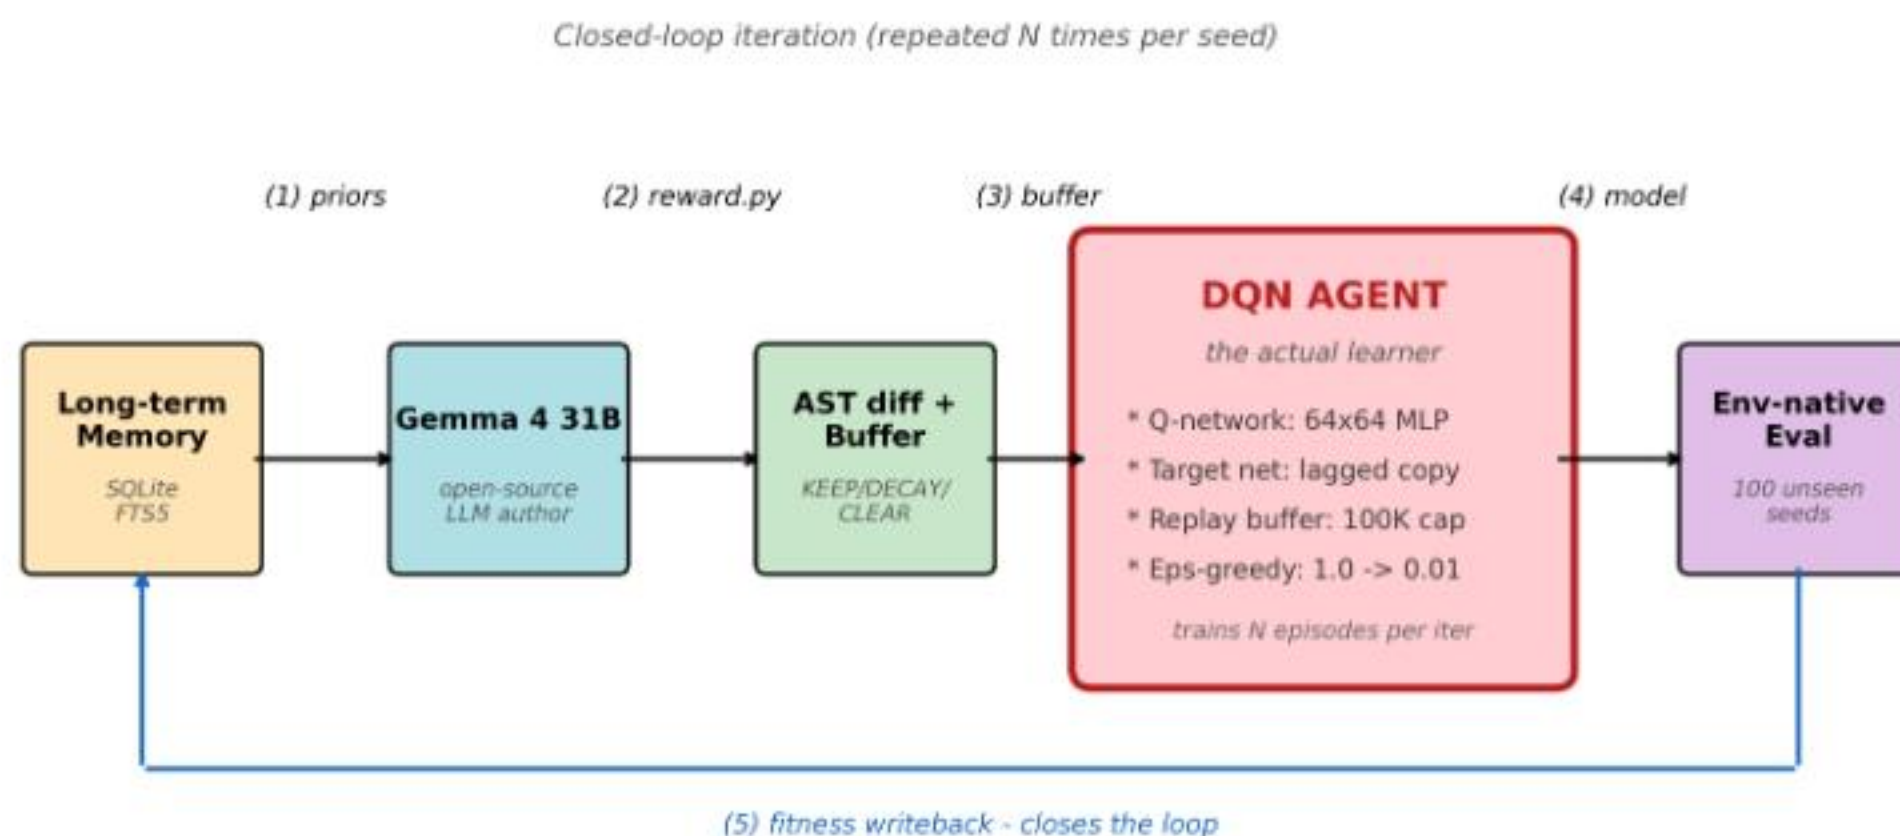
Shaping 理論基礎

Ng 1999 potential-based shaping，保證策略不變^[8]。

[4] Nous Hermes, 2026 [5] Stanford HAI, 2026 [6] GB-DQN, 2025 [7] CHAIN, NeurIPS 2024 [8] Ng et al., ICML 1999

系統總覽 · 三模組閉環 · 跑 5 輪

三個模組，共用同一把公平的尺



五步閉環：① Gemma 4 31B 寫獎勵^[1] → ② 四層記憶餵回饋、AST buffer 決定樣本去留 → ③ DQN 訓練 → ④ 100 顆未見 seed 公平評估 → ⑤ 結果寫回記憶，循環 5 輪。

[1] Ma et al., EUREKA, ICLR 2024 (reward-as-code 範式)

四層記憶 · 開源 REWARD AUTHOR

LAYER · 01 / 02

怎麼寫獎勵的「程序知識」+ 任務語意先驗，跨輪穩定保留。

長期・短期

LAYER · 03

每輪存下 **reward 原始碼 + fitness** ; 下輪用 fitness 取 **top-k** 回饋進 prompt 。

本研究核心迴路

LAYER . 04

當輪 scratchpad：彙整檢索到的記憶，組成本輪 reward 生成的上下文。

短期・富輪

Gemma 4 31B (開源) 取代 GPT-4 擔任 reward author，使整條管線可本地、可重現。

記憶化 + 開源化

[4] Nous Research, Hermes Agent (四層記憶啟發), 2026

03

AST-AWARE BUFFER MANAGER · DIFF 新舊 REWARD 的抽象語法樹

用程式碼差異決定樣本去留

改動 01
IDENTICAL
完全相同

改動 02
SIGNATURE_ONLY
僅介面變

改動 03
STRUCTURAL
結構性改寫

改動 04
TOTAL_REWRITE
整段重寫

↓ 對應的 BUFFER 動作 · BUFFER ACTION

→ IDENTICAL
KEEP
全保留

→ SIGNATURE
PARTIAL_KEEP
部分保留

→ STRUCTURAL
DECAY
衰減舊樣本

→ TOTAL_REWRITE
CLEAR
清空重來

[7] Tang & Berseth, CHAIN, NeurIPS 2024 (非穩態 buffer 動機)

4 環境 × 6 條件 × 5 SEED = 120 RUNS (+ PART 2 80)

LUNARLANDER 密集 · obs8/act4

CARTPOLE 稀疏 · +1/step

MOUNTAINCAR 稀疏 · -1/step

ACROBOT 稀疏 · -1/step

B0 · env-native

01

環境原生獎勵當基準。CartPole / MountainCar 成功率 0%。

B1 · handcrafted

02

作者手寫的獎勵 placeholder，不是人類專家 baseline。

B2 · gemma-oneshot

03

Gemma 單輪生獎勵，沒記憶、沒 buffer 管理。

B3 · hermes-full

04

完整系統：四層記憶 + AST buffer，閉環 5 輪。

B3 · no-memory

05

拿掉記憶的消融組——專問「記憶本身」有沒有用。

B3 · no-AST

06

拿掉 AST buffer 的消融組。兩組關鍵對照：B3-full vs B0、vs B3-no-memory。

ENV-NATIVE MEAN · N=5

六條件 × 四環境 結果總表

條件	LUNARLANDER 密集	CARTPOLE 稀疏	MOUNTAINCAR 稀疏	ACROBOT 稀疏
B0-env-native	173.22	154.80	-193.44	-194.96
B1-handcrafted	77.77	160.19	-140.40	-185.28
B2-gemma-oneshot	152.65	187.64	-153.09	-83.21
B3-hermes-full	153.56	334.44	-132.53	-82.92
B3-no-memory	248.77	243.21	-168.55	-83.23
B3-no-AST	95.42	220.81	-134.59	-83.58

稀疏環境 B3-hermes-full 全面領先 B0；密集 LunarLander 反而被 no-memory 超越。

DENSITY-DEPENDENT

[1] env-native eval · 100 unseen seeds


04

CH. 4 實驗結果 · 結果一 B3-FULL VS B0 (3/6)

12 / 18

系統有沒有用？

原生訊號越弱，塑形越有用




+116%	CartPole	稀疏 · P=.032 · WIN
+57.5%	Acrobot	稀疏 · P=.095 · 近 WIN
+31.5%	MountainCar	稀疏 · P=.011 · WIN
-11.4%	LunarLander	密集 · P=1.0 · 反轉 N.S.

數據直覺 · 訊號弱才需要塑形

← → 翻頁 · B 動態 · ESC 索引

密集獎勵下，「記憶」顯著有害



同一套 LLM 獎勵，差別只在記憶：無記憶穩穩落地，有記憶 **seed_43** 貼地懸停（11.6 分）。

[8] Ng et al., potential-based shaping, ICML 1999

B3 NO-MEMORY

248.77

無記憶時，LunarLander 平均回報穩定收在高分區。

B3 HERMES-FULL

153.56 **-38.3%** P=0.0317 · 顯著

記憶逼 LLM 一輪輪疊塑形、推離最優；三個稀疏環境效應 +37.5 / +21.4 / +0.4% 皆不顯著。機制：potential-based shaping drift [8]。


數據直覺 · 原生夠好時，記憶反而推離最優

← → 翻頁 · B 動態 · ESC 索引

04

分界線是「塑形空間有多大」，不是密度 · PER-SEED STD

塑形空間越大，變異就越大



穩 · 稀疏 · 近最優收斂

3.08 MountainCar



4.39 Acrobot



亂 · 塑形空間大 · 差一個數量級


113.18 CartPole



91.40 LunarLander



獎勵設計與 value network 架構 正交



9/9

稀疏 9 格

三變體全部正向；MountainCar 三變體皆顯著。

3/3

負 密集 LUNARLANDER

三變體皆負，密度反轉穩定。

 $p > 0.3$

HERMES 跨變體

三變體互比全部不顯著 → 與架構無關。

四項貢獻 · CONTRIBUTIONS

本研究建立了什麼

- 01

開源可行

開源 **Gemma 4 31B** 取代 GPT-4 擔任 reward author，整條管線可重現 [1]。

- 02

記憶有害（首次）

據我們所知，首次給出統計顯著的「記憶有害」結果（密集， $p=0.0317$ ） [8]。

- 03

變異性指紋

提出以 per-seed std 為「塑形空間大小」的診斷指紋。

- 04

模型無關性

效果與 value network 架構正交，框架可插拔（Part 2） [9][10]。

核 心 假 說 提出 **reward density** 假說 — 記憶在稀疏受益、在密集有風險。

研究限制 · 未來工作

研究限制與未來工作

L LIMITATIONS · 限制

- $n = 5$: 只測得出大效應 (Cohen's $d \geq 1$) , 中等效應 inconclusive 。
- 短訓練 budget : 測的是收斂速度, 不是天花板。
- B1 手工獎勵僅 placeholder , 主張只靠 B0 / B3 / B3-no-mem 。
- 單一 LLM ; density 與 shaping richness 在這 4 環境部分混淆。

F FUTURE WORKS · 未來工作

- 連續控制 **MuJoCo** ; 用 LunarLanderContinuous 拆開 density / richness 。
- **勢能約束**生成 : 把 shaping 限在 potential-based 子類 [8] 。
- 自適應迭代 : 依任務動態決定記憶要不要 opt-in 。
- 多 LLM 比較 : 檢驗「更大模型、變異更誇張」的預測。

[8] Ng et al., potential-based shaping, ICML 1999 github.com/oomao/Final_project_Group5_DRL

Q & A

Thank You

記憶不是免費升級：稀疏受益、密集有風險，應按任務 opt-in。