


記憶擴增之 大型語言模型 獎勵設計框架



開源 LLM (Gemma 4 31B) + 四層記憶 + AST-aware Replay Buffer · 自動為 DQN 設計獎勵函數

結論先講

「記憶」 不是萬靈丹。

幫不幫，看「獎勵密度」。這是這條線上第一個統計顯著的「記憶有害」結果。

+116%

稀疏獎勵 · SPARSE

記憶幫忙：增益 +31% ~ +116%。

-38%

密集獎勵 · DENSE

記憶顯著有害：-38.3%， $p = 0.0317$ 。

ICLR 2024 → 社群三延伸

三條線被當成能相加，
卻沒人驗證過

- 2024 +52% EUREKA:GPT-4 寫獎勵,83% 任務勝人類、平均 +52%。
- 延伸 ① OSS 換開源模型:省成本、可重現(取代 GPT-4)。
- 延伸 ② MEM 加記憶:跨輪 refine, 累積過往的獎勵設計經驗。
- 延伸 ③ BUF 處理 replay buffer:獎勵變→舊樣本失效→catastrophic forgetting。

EUREKA 勝率

83%

任務上勝過人類設計

平均增益

+52%

跨任務 reward 表現

社群延伸

3 條

被「預設」能疊加

研究缺口

0

從未經多環境 + 統計檢定驗證

4 環境 × 6 條件 × 5 SEED = 120 RUNS (+ PART 2 80 RUNS)

六個條件，
只比『有沒有記憶』



01

B0 · env-native

環境原生獎勵當基準。CartPole / MountainCar 成功率 0%。



02

B1 · handcrafted

作者手寫的獎勵 placeholder，不是人類專家 baseline。



03

B2 · gemma-oneshot

Gemma 單輪生獎勵，沒記憶、沒 buffer 管理。



04

B3 · hermes-full

完整系統：四層記憶 + AST buffer，閉環 5 輪。



05

B3 · no-memory

拿掉記憶的消融組——專問「記憶本身」有沒有用。



06

B3 · no-AST

拿掉 AST buffer 管理的消融組。統計：Mann-Whitney U + bootstrap 95% CI, n=5。

全場重心 · THE KEY RESULT

密集獎勵下，「記憶」顯著有害

B3 NO-MEMORY

248.77


沒記憶時，LunarLander 平均回報穩定收在高分區。

B3 HERMES-FULL

153.56

-38.3% $P = 0.0317$ · 顯著

加記憶後 LLM 一輪輪疊塑形，把策略推離最優。三個稀疏環境記憶效應 +37.5 / +21.4 / +0.4%，皆不顯著。機制假說：potential-based shaping drift (Ng et al. 1999)。



同一套 LLM 獎勵，差別只在記憶：無記憶穩穩落地，有記憶 **seed_43** 學會貼地懸停 (11.6 分)。

分界線是「塑形空間有多大」，不是密度

塑形空間越大，
變異就越大

3.08

MountainCar

稀疏・單一子目標 → 收斂到近最優，五個 seed 幾乎同值。



4.39

Acrobot

稀疏・同樣超穩,變異與 MountainCar 同一量級。



113.18

CartPole

高變異・塑形空間大→很多「似是而非」的獎勵，差一個數量級。




91.40

LunarLander

高變異·per-iteration 上下震盪(vs MountainCar 單調往上)。



獎勵設計與 value network 架構 正交



固定獎勵管線，只換 vanilla / Double / Dueling DQN。Part 1 的密度型態完

整重現 → 框架可插拔。

稀疏 9 格

9/9

三變體全部正向;MountainCar 三變體皆顯著。

密集 LUNARLANDER

3/3 負

三變體皆負,密度反轉穩定。

HERMES 跨媒體

$p > 0.3$

三變體互比全部不顯著 → 與架構無關。

TAKEAWAY

稀疏成立、密集反轉；
記憶不是免費升級，
密集顯著有害

EUREKA 那套搬到開源 Gemma：候選指標是 **reward density**。

實務建議

記憶要按任務 **opt-in**，不是預設打開。

三個可證偽預測 · FALSIFIABLE PREDICTIONS

01 原生「密但沒對齊」的任務，記憶反而會幫忙。

02 光靠 density 不夠，要「稀疏 / 密集 × 塑形豐富 / 貧乏」二維分類。

03 更大的 LLM 變異更誇張：上限更高，崩潰風險也更高。

Q & A

記憶， 請按任務 opt-in。

首次用多環境 + 統計檢定，驗證「記憶」對
LLM 獎勵設計的價值，是看任務的。

-
- 01 稀疏受益 · 密集反轉
+116% / +31.5% / +57.5% (稀疏 WIN) ; LunarLander -11.4% (密集打平) 。
-
- 02 記憶顯著有害 (密集)
248 → 153, -38.3%, $p = 0.0317$; 與 DQN 架構正交 (Part 2) 。
-
- 03 候選指標 = **reward density**
記憶按任務 opt-in, 不是預設打開; 三個可證偽預測待檢驗。
-